

Practical methods for competing risks data

A review

Beatriz Lima Silveira

Felipe Mancini Ramos

Universidade Federal de Minas Gerais

Slides disponíveis em **GitHub**

Tópicos

- Introdução
- Conceitos básicos de Análise de Sobrevida
- Cause-Specific Hazard
- Estimação da Incidência Cumulativa (CIF)
- Modelo de Cox para hazards específicos por causa
- Modelo de Subdistribuição de Riscos
- Análise de sensibilidade
- Aplicação: Base de Dados CASCADE
- Referências

Introdução

Em análise de sobrevivência, o interesse está no tempo até a ocorrência de um evento, sendo o arcabouço teórico tradicional desenvolvido considerando um único evento. Entretanto, em muitos cenários reais, os indivíduos estão sujeitos a **múltiplos eventos concorrentes**, denominados **riscos competitivos**. Abordagens tradicionais para riscos competitivos buscavam estimar o tempo até um evento específico em um cenário hipotético sem os eventos concorrentes, exigindo **pressupostos fortes e não verificáveis**. Em contraste, métodos modernos concentram-se em quantidades diretamente estimáveis a partir dos dados observados, como as **cause-specific hazards (taxas de riscos específicos por causa)** e a **cumulative incidence estimation (Incidências cumulativas de estimação)**. Esta apresentação revisa os métodos mais modernos para análise de riscos competitivos apresentados no artigo *“Practical methods for competing risks data: A review”* de Giorgos Bakoyannis e Giota Touloumi, com foco em modelos do tipo Cox, aplicados nos dados do estudo

CASCADE sobre interrupção e troca de terapia antirretroviral em indivíduos infectados pelo HIV.

Análise de Sobrevivência

- Estuda o tempo até a ocorrência de um evento de interesse (tempo de falha).
 - Tempo até a morte.
 - Tempo até a recidiva de uma doença.
 - Tempo até a interrupção de um tratamento.
- Abrange uma vasta amplitude de áreas. Engenheiros estudam a confiabilidade de uma estrutura, sociólogos investigam tempo entre marcos sociais0 cíclicos, economistas concentram em tempo de promoção e o judiciário se atenta a tempo de reincidência do crime após liberação.
- Complexidades
 - Tempos de Sobrevivência são não negativos e geralmente assimétricos.
 - Experimentos de tempo de vida são muito suscetíveis a casos de **censura**.

Análise de Sobrevivência

Censura

- Definimos como censura uma observação parcial do tempo de falha, e ela pode ocorrer por uma infinidade de fatores.
 - Fim do tempo previsto para o experimento.
 - Perda de acompanhamento do indivíduo.
 - Coleta ineficaz dos dados.
- O poder de lidar com essas observações parciais, além da plétora de aplicações, faz da análise de sobrevivência uma das áreas mais citadas da estatística.

Análise de Sobrevivência

Funções de Interesse

Seja T uma variável aleatória contínua representando o tempo até a ocorrência de um evento de interesse.

- A função de sobrevivência de T fornece a probabilidade que um indivíduo sobreviva após um dado tempo t :

$$S(t) = P(T > t)$$

- A função taxa de falha de T , que para cada momento t corresponde a taxa de falha instantânea naquele momento:

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t < T < t + \Delta t | T > t)}{\Delta t}$$

Análise de Sobrevivência

Funções de Interesse

- A função taxa de falha acumulada, dada por:

$$H(t) = \int_0^t h(u)du$$

- A função de riscos, dada por:

$$R(t) = \frac{P(T \leq t)}{P(T > t)} = \frac{F(t)}{S(t)}$$

Análise de Sobrevivência

Funções de Interesse

É fácil mostrar que:

$$h(t) = \frac{f(t)}{S(t)}$$

$$f(t) = -\frac{d}{dt}S(t)$$

$$S(t) = e^{-H(t)}$$

$$R(t) = e^{H(t)} - 1$$

Análise de Sobrevivência

Dados de Sobrevivência

Uma base de dados para um estudo de análise de sobrevivência é composto pelos seguintes itens:

- Tempo de sobrevivência observado (T).
- Indicador de censura (δ).
- Covariáveis de interesse (X).

Análise de Sobrevivência

Estimador de Kaplan - Meier

Método não paramétrico de estimar a curva de sobrevivência. Dado uma amostra:

- Sejam $t_1 < t_2 < \dots < t_m$ os tempos distintos ordenados de sobrevivência.
- Sejam d_j o número de falhas em t_j , $j = 1, \dots, m$.
- Sejam n_j o número de indivíduos sob risco em t_j , $j = 1, \dots, m$.

O estimador de Kaplan-Meier é definido como:

$$\hat{S}(t) = \prod_{j: t_j < t} (1 - d_j/n_j)$$

- Estimador de Máxima Verossimilhança de para $S(t)$.

- Não viciado para grandes amostras, fracamente consistente e assintoticamente Gaussiano.

Modelo de Riscos Competitivos

Dados de risco competitivos são encontrados em estudos onde os participantes estão sobre risco de 2 ou mais causas mutualmente exclusivas. Por exemplo: - Morte devido a doença crônica ou morte por outras causas naturais. - Fim de uma empresa devido a falência ou devido a aquisição da mesma. - Remoção de um curso por reprovação ou por mudança de curso.

Continuamos interessados no tempo de sobrevivência do indivíduo (T) e continuamos lidando com as censuras (δ) e observando covariáveis (X), mas agora trabalhamos também com uma indicadora de causa C .

Primeira Abordagem

No passado, os estudos de risco competitivos buscavam inferir sobre a distribuição do tempo até uma falha por causa específica na ausência hipotética dos outros, da seguinte forma:

Dados k riscos competindo, suponha que existam $T_1, \dots, T_k$ tempos de sobrevivência latentes para cada causa, então observamos apenas $T = \min\{T_k\}$ e a causa da falha (C). Para estimar a função distribuição $T_i(t)$ para cada causa $i = 1, \dots, k$, podemos tratar qualquer tempo cuja causa não seja i como censura (uma observação parcial de T_i), aplicar o estimador de Kaplan-Meier para achar $\hat{S}_i(t)$ e tomar $\hat{F}_i(t) = 1 - \hat{S}_i(t)$.

Seguiria então que $\hat{F}(t) = \hat{P}(T = \min\{T_k\} \leq t) = \sum_{i=1}^k \hat{F}_i(t)$.

Problema!

- Nem a distribuição conjunta, nem as correspondentes distribuições marginais para as causas são identificáveis pelos dados observados sem fortes hipóteses adicionais, como por exemplo a independência desses tempos latentes.
- Pior ainda, essas hipóteses não podem ser testadas, uma vez que não observamos esses tempos latentes.
- Inclusive, aplicações já mostraram como o estimador Naive Kaplan Meier $\hat{F}(t)$ produz valores maiores que um para a função de distribuição.
- Este modelo estima corretamente a incidência acumulativa no caso hipotético onde falhas por riscos competitivos foram eliminados e que a taxa de falha específica para a causa não se altera após eliminar outro risco.

Cause-specific Hazard

Na abordagem moderna de riscos competitivos, o interesse concentra-se em quantidades diretamente observáveis: o tempo até a ocorrência do evento (T) e a causa associada (C).

O **risco específico por causa** para a causa (j) é definido como a taxa instantânea de ocorrência dessa causa entre os indivíduos que ainda não apresentaram nenhum evento:

$$\lambda_j(t) = \lim_{h \rightarrow 0} \frac{P(t \leq T < t + h, ; C = j \mid T \geq t)}{h}$$

O risco total é obtido pela soma dos riscos específicos:

$$\lambda(t) = \sum_{j=1}^k \lambda_j(t)$$

Essa relação decorre da aditividade das probabilidades para eventos mutuamente exclusivos e não requer hipóteses de independência entre os tempos de falha.

Cumulative incidence estimation

Em muitos estudos, o interesse está na probabilidade de ocorrência de uma causa específica ao longo do tempo.

A **Função de Incidência Cumulativa (CIF)** para a causa (j) é definida por:

$$F_j(t) = P(T \leq t, ; C = j)$$

e representa a probabilidade acumulada de falha pela causa (j) até o tempo (t), considerando explicitamente a presença dos eventos concorrentes.

A CIF pode ser expressa em função dos riscos específicos por causa:

$$F_j(t) = \int_0^t \lambda_j(u) \exp\left(-\int_0^u \sum_{c=1}^k \lambda_c(w), dw\right) du$$

Principais características

- Possui interpretação direta como probabilidade;
- Incorpora a competição entre os diferentes tipos de evento;

- É a principal ferramenta para descrever a incidência de uma causa específica em estudos com riscos competitivos.

Cumulative incidence estimation

Estimando a Cumulative Incidence Function

A CIF pode ser estimada por um estimador não paramétrico que combina os riscos específicos por causa com a probabilidade de sobrevivência global:

$$\hat{F}_j(t) = \sum_{m: t_m \leq t} \hat{\lambda}_j(t_m) \hat{S}(t_{m-1})$$

$$\hat{\lambda}_j(t_m) = \frac{d_{jm}}{n_m} \quad \text{e} \quad \hat{S}(t_{m-1}) = \prod_{i=1}^{m-1} \left(1 - \frac{d_i}{n_i} \right).$$

onde:

- t_m : m-ésimo tempo ordenado de falha;
- d_{jm} : número de falhas da causa j em t_m ;
- d_m : número total de falhas (todas as causas) em t_m ;

- n_m : número de indivíduos em risco imediatamente antes de t_m ;
- $\hat{\lambda}_j(t_m)$: risco específico estimado para a causa j ;
- $\hat{S}(t_{m-1})$: estimador de Kaplan-Meier da sobrevivência global até o instante anterior.

Cumulative incidence estimation

Por que não utilizar o estimador ingênuo?

Em análises de sobrevivência sem riscos competitivos,

$$F(t) = P(T \leq t) = 1 - S(t),$$

de modo que $(1-S(t))$ representa a probabilidade acumulada de ocorrência do evento.

Em riscos competitivos, uma prática comum era estimar a incidência da causa (j) por

$$1 - \hat{S}_j(t),$$

tratando as falhas por outras causas como observações censuradas.

Warning

Essa abordagem assume implicitamente que indivíduos que falharam por outras causas ainda poderiam apresentar o evento de interesse no futuro.

Como consequência,

$$1 - \hat{S}_j(t) \geq \hat{F}_j(t),$$

isto é, o estimador ingênuo tende a superestimar a incidência acumulada da causa (j).

Modelo de Cox

O modelo de riscos proporcionais, proposto por Cox em 1972 como uma maneira de incluir covariáveis na análise, tem a forma:

$$h(t|X) = h_0(t)\exp(X\beta)$$

Onde: - $h_0(t)$ é uma função taxa de falha basal. - X é o vetor de covariáveis. - β é um vetor de coeficientes de regressão para serem estimados.

Modelo de Cox

O modelo ganha o nome de riscos proporcionais uma vez que dados dois elementos distintos (x_i, x_j) , a razão das taxas de falhas de ambos é independente do tempo:

$$\frac{h(t|x_i)}{h(t|x_j)} = \frac{h_0(t)\exp(x_i\beta)}{h_0(t)\exp(x_j\beta)} = \exp(x_i\beta - x_j\beta)$$

Modelando taxa de falhas para causas específicas

Para investigar como as covariáveis X podem afetar a taxa de falha instantânea devido a uma causa na presença de todas as outras, um método análogo ao de taxas de falha proporcionais de Cox foi proposto para o cenário de riscos competitivos:

$$\lambda_j(t, X) = \lambda_{0j}(t) \exp(\beta_j X)$$

Na prática, esse modelo pode ser estimado tratando falhas de outras causas como censuras e ajustando um modelo Cox tradicional sem as fortes hipóteses discutidas antes, isto é, trabalhar isoladamente.

Modelando taxa de falhas para causas específicas

Para evitar esse trabalho isolado, foram desenvolvidos métodos de aumento de dados para modelar taxas de falha para todas as causas e testar a igualdade dos efeitos das covariáveis nos modelos de falhas diferentes.

Para isso, devemos trabalhar com os dados em um “formato longo” - Cada indivíduo deve ter k indicadoras de causa. - Cada covariável de interesse deve gerar k subvariáveis específicas a causa, de tal forma que no caso de j -ésima falha, a j -ésima subcovariável valha o valor original e todas as outras valham zero.

Modelando taxa de falhas para causas específicas

Feito isso, restam duas abordagens:

- Estratificar por causa de falha: este modelo gera estimativas idênticas a modelagem isolada.
- Incluir a causa de falha (C) como covariável: este modelo assume taxas de falha proporcionais.

Nas duas abordagens, o efeito de uma covariável no tempo de falha em cada causa pode ser estimado incluindo no modelo suas subcovariáveis correspondentes.

Também é possível incluir no modelo termos de interação da covariável com a causa de falha, para testar se o efeito da covariável é comum entre as causas. No caso afirmativo, a eficiência do modelo aumenta.

Modelo Fine and Gray

Modelar apenas as taxas de falhas instantaneas não quantifica o ganho ou perda geral que uma covariável imbui no tempo de falha, logo modelar a incidencia acumulativa pode tornar a interpretação mais relevante. Um modelo deste tipo foi sugerido por Fine and Gray.

Defina a taxa de falha de subdistribuição (subdistribution hazard) como:

$$\begin{aligned}\lambda_j^{sub}(t, x) &= \lim_{h \rightarrow 0} \frac{1}{h} P[t \leq T < t + h, C = j | T \geq t \cup (T \leq t \cap C \neq j), X] \\ &= \frac{-d}{dt} \log[1 - F_j(t, X)]\end{aligned}$$

Note que esse não é a taxa da falha natural pois inclui no tempo t sujeitos que falharam por outras causas antes de t e não estão mais em risco.

Modelo Fine and Gray

Com essa taxa de falha, foi proposto um modelo semiparamétrico de taxa de falha proporcional:

$$\lambda_j^{sub}(t, x) = \lambda_{0j}^{sub}(t, x) \exp(\beta_j X)$$

Análise de Sensibilidade

O que é análise de sensibilidade?

Uma análise de sensibilidade investiga o quanto as conclusões de um modelo dependem de hipóteses assumidas durante a estimação.

Em riscos competitivos, o modelo de Fine & Gray pode ser ajustado sob diferentes mecanismos de censura:

- **Censura administrativa;**
- **Censura aleatória (random censoring).**

A questão central é:

As estimativas permanecem semelhantes quando utilizamos uma hipótese simplificadora em vez de um método mais geral?

Se os resultados mudarem pouco, o método é considerado robusto à violação da hipótese.

Análise de Sensibilidade

Qual hipótese está sendo investigada?

No modelo de Fine & Gray, a inferência é mais simples quando toda censura ocorre devido ao encerramento do estudo.

Nesse caso, para cada indivíduo:

$$d_i = d - W_i$$

onde:

- d : duração total do estudo;
- W_i : instante de entrada do indivíduo;
- d_i : tempo de censura administrativa.

Entretanto, na prática podem existir perdas de seguimento antes do término do estudo.

Análise de Sensibilidade

Qual hipótese está sendo investigada?

Assim, a censura observada pode ser:

$\min(U_i, d_i)$,

onde:

- U_i : censura aleatória;
- d_i : censura administrativa.

Warning

A análise de sensibilidade avalia o impacto de assumir apenas censura administrativa quando a censura aleatória também está presente.

Simulação

Como a sensibilidade foi avaliada?

Os autores geraram dados simulados com:

- Dois eventos competitivos;
- Um único preditor (x);
- Diferentes probabilidades do evento de interesse;
- Diferentes intensidades de censura;
- Diferentes durações do estudo.

Para cada cenário foram comparadas duas abordagens:

1. **Modelo assumindo censura administrativa;**
2. **Modelo utilizando IPCW (Inverse Probability of Censoring Weighting).**

Simulação

Como a sensibilidade foi avaliada?

O objetivo foi verificar:

- Viés na estimativa do efeito da covariável;
- Cobertura dos intervalos de confiança;
- Condições nas quais a hipótese de censura administrativa se torna inadequada.

⚠ Important

Se os resultados dos dois métodos forem semelhantes, a hipótese de censura administrativa pode ser considerada aceitável naquele cenário.

Simulação

Construção dos cenários

A causa de falha foi simulada por uma variável $C \in 1, 2$, onde:

- $C = 1$: evento de interesse;
- $C = 2$: evento competitivo.

A probabilidade de ocorrência do evento de interesse foi definida por

$$P(C = 1|x) = 1 - (1 - p)^{\exp(0.5x)},$$

onde:

- $p \in 0.3, 0.5, 0.7$ controla a frequência do evento de interesse;
- x representa a covariável simulada.

Foram considerados dois tipos de covariável:

- $x \sim N(0, 1)$ (contínua);

- $x \sim \textit{Bernoulli}(0.4)$ (binária).

Dessa forma, diferentes cenários apresentavam proporções distintas entre evento de interesse e evento competitivo.

Simulação

Geração dos tempos de falha

Após determinar a causa de falha, os tempos foram gerados condicionalmente à causa.

Para o evento de interesse ($C = 1$):

$$P(T \leq t | C = 1, x) = \frac{1 - (1 - p[1 - \exp(-t)])^{\exp(0.5x)}}{1 - (1 - p)^{\exp(0.5x)}}.$$

Para o evento competitivo ($C = 2$):

$$P(T \leq t | C = 2, x) = 1 - \exp[-\exp(\gamma x)t].$$

O parâmetro $\gamma \in 0.5, -0.5, -1$ controla o efeito da covariável sobre o evento competitivo. Os autores variaram γ para investigar situações em que a covariável possui efeitos semelhantes ou conflitantes entre as duas causas de falha.

Simulação

Introdução da censura

A censura aleatória foi gerada por $U_i \sim \text{Exp}(\lambda)$ com $\lambda \in 0.2, 0.25, 0.5, 1, 2, 4$
O instante de entrada no estudo foi gerado por $W_i \sim U(0, 1)$ e a censura administrativa foi definida como $d_i = d - W_i$ onde $d \in 1, 2, 4, 8$ representa a duração total do estudo.

O tempo observado foi

$$Y_i = \min(T_i, U_i, d_i)$$

Assim, a simulação permitiu avaliar simultaneamente o impacto de:

- duração do estudo;
- intensidade da censura;
- frequência do evento de interesse;
- efeito da covariável sobre o evento competitivo.

No total foram avaliados $4 \times 6 \times 3 \times 3 \times 2 = 432$ cenários distintos.

Aplicação: Estudo CASCADE

O estudo *Concerted Action on SeroConversion to AIDS and Death in Europe* (CASCADE) avaliou mudanças no tratamento antirretroviral em indivíduos infectados pelo HIV.

Eventos considerados

- **TI**: interrupção do tratamento (*treatment interruption*);
- **NH**: troca para um novo esquema terapêutico (*new HAART regimen*).

Resumo da amostra

- Total de participantes: **1551**;
- Interrupção do tratamento (TI): **299 (19,3%)**;
- Troca para novo regime (NH): **283 (18,2%)**;
- Nenhum dos dois eventos: **969 (62,5%)**.

Durante o acompanhamento ocorreram **98 óbitos**, sendo **58 antes da ocorrência de TI ou NH**. Para esses indivíduos, o acompanhamento foi censurado na data do óbito.

Resultados

Kaplan-Meier versus CIF

As estimativas da incidência cumulativa foram obtidas utilizando:

- o estimador apropriado da CIF;
- o estimador ingênuo baseado em Kaplan-Meier.

Incidência acumulada em 4 anos

Evento	CIF	1 – KM
TI	26,7%	31,5%
NH	25,0%	29,5%

Principais resultados

- O estimador baseado em Kaplan-Meier superestimou sistematicamente a incidência dos dois eventos;
- A diferença observada confirma a importância de considerar explicitamente os riscos competitivos;

- Apenas **37,5%** dos pacientes experimentaram um dos dois eventos durante o acompanhamento.

Resultados

Kaplan-Meier versus CIF

Resultados

Efeito de Gênero em Interrupção ou Troca de Tratamento

Abordaremos a análise do efeito de gênero na taxa de falha instantânea através de 3 métodos:

- Isolado (A): onde ajustamos um modelo para cada causa tendo gênero como covariável de interesse.
- Estratificado (B): onde ajustamos o modelo simultaneamente para ambos riscos usando o aumento de dados e depois estratificamos pela variável causa de falha.
- Causal (C): onde ajustamos o modelo simultaneamente para ambos riscos usando o aumento de dados e incluímos a causa de falha como covariável.

Lembre que:

- As estimativas de (B) deveriam ser idênticas a de (A).
- O método (C) supõe taxas de falha proporcionais.

- Analisamos a interação da covariável com o tipo de falha, sabendo que um efeito comum da covariável entre os tipos de falha (interação não sig) nos garante maior eficácia.

Resultados

Efeito de Gênero em Interrupção ou Troca de Tratamento

Resultados

Efeito de Gênero em Interrupção ou Troca de Tratamento

Os três modelos concluíram efeito significativo do gênero no tempo até a interrupção do tratamento, com o risco para mulheres sendo 1.7 vezes maior que o risco para homens. Mas não houve efeito significativa no tempo até a troca de tratamento. Como esperado, as estimativas do modelo isolado foram idênticas as estimativas do modelo estratificado (0.531).

A interação entre gênero e causa é tida como significativa, uma vez que o efeito do gênero na interrupção do tratamento é diferente do efeito na troca de tratamento. O modelo causal não indicou diferença na taxa de falha basal para causas diferentes, nem apontou interação significativa entre gênero e causa. Um gráfico omitido pelos autores mostra as curvas de cada grupo cruzando, rejeitando a hipótese de taxas de falha proporcionais e portanto a eficácia deste modelo.

Resultados

Efeito de Gênero em Interrupção ou Troca de Tratamento

Um gráfico que mostre o efeito da covariável gênero para o risco do evento TI não servirá de muito. No cenário de riscos competitivos, a função taxa de falha e função distribuição acumulada não são relacionadas um a um, uma vez que a acumulada é uma função de todas as taxas de falhas de cada risco, e uma covariável pode afetar cada uma delas de forma diferente. Um aumento na acumulada pode vir de um efeito positivo para uma causa ou de um efeito negativo em uma causa concorrente. Simulamos a função distribuição acumulada para interrupção de tratamento, estimada pelo modelo (A), tomando valores diferentes para a interação entre gênero e mudança de tratamento (que em nosso caso é nula). Ao aumentarmos a interação, mais mulheres sofrem mudança de tratamento e portanto não podem sofrer o risco competindo de interrupção de tratamento. Para valores maiores as curvas chegam a

cruzar, mesmo as mulheres tendo risco significativamente maior de interrupção de tratamento.

Resultados

Efeito de Gênero em Interrupção ou Troca de Tratamento

Resultados

Estudo de Simulação

O estudo de simulação avaliou o impacto de assumir censura administrativa quando, na realidade, a censura era informativa.

Principais resultados

- O viés na estimativa do efeito da covariável permaneceu abaixo de **20%** em todos os cenários avaliados;
- A magnitude do viés não dependeu de um único fator, mas da combinação de diferentes características do estudo;
- Os maiores vieses ocorreram em cenários com:
 - alta taxa de censura;
 - longo tempo de acompanhamento;
 - elevada frequência do evento competitivo;
 - forte efeito da covariável sobre o evento competitivo.

⚠ Important

Os cenários mais críticos apresentaram vieses entre $-7,6\%$ e $19,9\%$.

Resultados

Estudo de Simulação

Resultados

Impacto da Censura Informativa

Quando a probabilidade acumulada de censura era moderada ($< 50\%$), os resultados mostraram boa robustez:

- Viés entre $-3,2\%$ e $6,4\%$;
- Probabilidade de cobertura próxima ao nível nominal;
- Pequena diferença entre os métodos avaliados.

Conclusão

A análise de sensibilidade indica que assumir censura administrativa produz resultados semelhantes aos obtidos com IPCW em muitos cenários práticos. Entretanto, diferenças relevantes podem surgir quando há:

- censura intensa;
- longo período de acompanhamento;

- forte associação entre covariáveis e eventos competitivos.

Resultados

Modelo Fine and Gray

A modelagem para a incidência acumulada usando taxas de falha de subdistribuição proposta por Fine and Gray pode ser realizada no R através do pacote `cmprsk`.

Repetimos a análise do efeito de gênero, desta vez na incidência acumulada, das 3 formas discutidas anteriormente:

- Assumindo censura administrativa.
- Lidando com censura aleatória através da IPCW (inverse probability of censoring weighting).
- Otimizando as pesagens do IPCW de acordo com a data de início do tratamento.

Resultados

Modelo Fine and Gray

Conclusão

- A análise de riscos competitivos deve se concentrar em quantidades **identificáveis**:
 - *Cause-Specific Hazard* (CSH);
 - *Cumulative Incidence Function* (CIF).
- A abordagem baseada em **tempos latentes de falha** depende de pressupostos não testáveis e apresenta problemas de identificabilidade.
- O estimador de **Kaplan-Meier** superestima a incidência de um evento na presença de riscos competitivos e não deve ser utilizado para esse propósito.
- O modelo de **Cox** permite avaliar o efeito das covariáveis sobre as **hazards específicas por causa**.
- O modelo de **Fine & Gray** permite modelar diretamente a **incidência cumulativa**.

- O efeito de uma covariável sobre a hazard específica por causa pode ser diferente de seu efeito sobre a CIF.

Conclusão

- A análise pode ser afetada por:
 - censura;
 - covariáveis dependentes do tempo;
 - causas de falha ausentes;
 - truncamento à esquerda;
 - violações da hipótese de riscos proporcionais.
- Os modelos semiparamétricos são amplamente utilizados por sua flexibilidade e facilidade de implementação.

Referências

- BAKOYANNIS, Giorgos; TOULOUMI, Giota. *Practical methods for competing risks data: A review*. Statistical Methods in Medical Research, v. 21, n. 3, p. 257–272, 2012. DOI: 10.1177/0962280210394479.
- COLOSIMO, Enrico Antônio; GIOLO, Suely Ruiz. *Análise de sobrevivência aplicada*. 2. ed. São Paulo: Blucher, 2024.
- PUTTER, Hein; FIOCCO, Marta; GESKUS, Ronald B. *Tutorial in biostatistics: Competing risks and multi-state models*. Statistics in Medicine, v. 26, n. 11, p. 2389–2430, 2007. DOI: 10.1002/sim.2712.



Speaker notes